

- Revisão de teoria da probabilidade
- Inferência probabilística
- Regras de Bayes
- Combinação de evidências

Recapitulando teoria da probabilidade...

- Determina o **grau de crença**
- Baseado em eventos
- Valor muda à medida que a informação aumenta
- Exemplo:
 - Existe 80% de crença/chance de que vai chover.
 - Tendo sido analisados 10 dias, em oito deles choveu e outros 2 não choveu. Se a análise mudar para 11 dias, essa probabilidade muda.

Teoria da probabilidade

- Qual o significado da sinalização abaixo?



Teoria da probabilidade

- Qual o significado da sinalização abaixo?



O valor 95% é

determinado pela

função densidade:

indica a frequência

relativa de uma

situação x em um

conjunto A

5

Notação básica

- Como as afirmações lógicas, as afirmações probabilísticas são acerca de **mundos possíveis** (quão prováveis são os vários mundos)
- O conjunto de todos os mundos possíveis é chamado **espaço amostral**
 - Ex: Se jogamos 2 dados distintos, existem 36 mundo possíveis (combinações).

Notação básica

- Considere: Ω um espaço amostral e ω elementos do espaço
 - Um **modelo de probabilidade** totalmente especificado associa uma probabilidade numérica $P(\omega)$ a cada mundo possível.
 - Todo mundo possível tem uma probabilidade entre 0 e 1
 - $0 \leq P(\omega) \leq 1$
 - A probabilidade do espaço amostral é 1.
 - $\sum_{\omega \in \Omega} P(\omega) = 1$

- Ex: Se assumirmos que os dois dados não são “viciados” e um lançamento não interfere no outro, cada um dos mundos possíveis (combinações) tem probabilidade $1/36$.

7

Notação básica

- Afirmações probabilísticas geralmente não são sobre mundos possíveis particulares, mas sobre os seus conjuntos.
 - Exemplo, poderíamos estar interessados nos casos em que os dois dados chegam ao resultado 11.
- Esses conjuntos são chamados **eventos**.
- Em IA os conjuntos são sempre descritos por **proposições** em uma linguagem formal.
- A probabilidade associada a uma proposição é definida como sendo a soma das probabilidades dos mundos nos quais é válida:
 - Para qualquer proposição ϕ , $P(\phi) = \sum_{\omega \in \phi} P(\omega)$
 - Ex: $P(\text{Total}=11) = P((5,6)) + P((6,5)) = 1/36 + 1/36 = 1/18$

8

- Probabilidades como $P(\text{Total}=11)$ são chamadas **probabilidades incondicionais** ou **anteriores**:
 - Grau de crença em proposições na ausência de qualquer outra informação
 - Ex: **P(cárie)** – probabilidade incondicional (check-up)
- Quando há alguma informação (evidência), tem-se a probabilidade condicional ou posterior
 - Ex: **P (cárie | dor de dente)** – probabilidade condicional
- As probabilidades condicionais são definidas em termos de probabilidades incondicionais:

$$P(a|b) = \frac{P(a \wedge b)}{P(b)}$$

- Pode-se combinar as proposições elementares usando conectivos da lógica proposicional:
- $P(\text{cárie} | \neg \text{dor de dente} \wedge \text{adolescente}) = 1$
- As probabilidades de todos os valores possíveis de uma variável aleatória pode ser escrita como **distribuição de probabilidade**:
 $P(\text{Tempo}) = \langle 0,6; 0,1; 0,29; 0,01 \rangle$ que equivale à:

$$\begin{aligned} P(\text{Tempo}=\text{ensolarado}) &= 0,6 \\ P(\text{Tempo}=\text{chuvoso}) &= 0,1 \\ P(\text{Tempo}=\text{nublado}) &= 0,29 \\ P(\text{Tempo}=\text{neve}) &= 0,01 \end{aligned}$$

- Um mundo possível é representado por um conjunto de variável/pares de valor
- Na teoria da probabilidade, as variáveis são chamadas **variáveis aleatórias** e seus nomes começam com letra maiúscula.
 - Ex: Variáveis aleatórias: Total e Dado1
- Cada variável aleatória tem um **domínio** (conjunto de valores possíveis que pode assumir)
 - Ex: O domínio de Dado1 é $\{1, \dots, 6\}$, assim como o domínio de Idade pode ser {juvenil, adolescente, adulto}
- Os valores são sempre minúsculos e podem ser finitos ou infinitos

- Quando a variável aleatória pode assumir um número infinito de valores, tem-se uma **função densidade de probabilidade (fdp)**.
 - Ex: $P(\text{TempMeioDia}=x) = \text{Uniforme}_{[18;26]}$
 - A temperatura ao meio dia é distribuída uniformemente entre 18 e 26 graus Celsius.
- A distribuição sobre variáveis múltiplas é chamada **distribuição de probabilidade conjunta**
 - Ex: $P(\text{Tempo}, \text{Cárie})$ = tabela de probabilidades 4×2 .

Notação básica

- Um mundo possível é definido para ser uma atribuição de valores a todas as variáveis aleatórias consideradas.
 - Ex: se as variáveis aleatórias são Cárie, Dor de dente e Tempo, então existem $2 \times 2 \times 4 = 16$ mundos possíveis.

13

Inferência probabilística

- Computação de probabilidades posteriores de proposições de consulta dada uma evidência observada.
- Base de conhecimento: **distribuição conjunta total**
- Considere a distribuição conjunta total para o mundo DorDeDente, Cárie, Boticão:

	<i>dordedente</i>		<i>~dordedente</i>	
	<i>boticão</i>	<i>~boticão</i>	<i>boticão</i>	<i>~boticão</i>
<i>cárie</i>	0,108	0,012	0,072	0,008
<i>~cárie</i>	0,016	0,064	0,144	0,576

14

Inferência probabilística

- $P(\text{cárie}) = ?$

	<i>dordedente</i>		<i>~dordedente</i>	
	<i>boticão</i>	<i>~boticão</i>	<i>boticão</i>	<i>~boticão</i>
<i>cárie</i>	0,108	0,012	0,072	0,008
<i>~cárie</i>	0,016	0,064	0,144	0,576

15

Inferência probabilística

- $P(\text{cárie}) = 0,108 + 0,012 + 0,072 + 0,008 = 0,2$

	<i>dordedente</i>		<i>~dordedente</i>	
	<i>boticão</i>	<i>~boticão</i>	<i>boticão</i>	<i>~boticão</i>
<i>cárie</i>	0,108	0,012	0,072	0,008
<i>~cárie</i>	0,016	0,064	0,144	0,576

16

Inferência probabilística

- $P(\text{cárie}) = 0,108 + 0,012 + 0,072 + 0,008 = 0,2$

	dordedente		~dordedente	
	botião	~botião	botião	~botião
cárie	0,108	0,012	0,072	0,008
~cárie	0,016	0,064	0,144	0,576

Probabilidade marginal

17

Inferência probabilística

- $P(\text{cárie}|\text{dordedente}) = ?$

	dordedente		~dordedente	
	botião	~botião	botião	~botião
cárie	0,108	0,012	0,072	0,008
~cárie	0,016	0,064	0,144	0,576

18

Inferência probabilística

- $P(\text{cárie}|\text{dordedente}) = P(\text{cárie} \wedge \text{dordedente}) / P(\text{dordedente}) = 0,108 + 0,012 / 0,108 + 0,012 + 0,016 + 0,064 = 0,6$

	dordedente		~dordedente	
	botião	~botião	botião	~botião
cárie	0,108	0,012	0,072	0,008
~cárie	0,016	0,064	0,144	0,576

Probabilidade condicional

19

Independência

- Para expandir a distribuição conjunta total, podemos adicionar a variável Tempo.
- A distribuição conjunta total agora será: $P(\text{dordedente}, \text{botião}, \text{cárie}, \text{tempo}) = 2 \times 2 \times 2 \times 4 = 32$
- Considerando que o tempo é **independente** dos problemas dentários de alguém, então a tabela de 32 elementos pode ser reduzida para uma tabela de oito elementos e uma tabela de 4 elementos.
- A independência entre as proposições a e b pode ser escrita como:
 - $P(a|b) = P(a)$ ou $P(b|a) = P(b)$ ou $P(a \wedge b) = P(a)P(b)$

20

Independência condicional

- Se eu tenho cárie, a probabilidade do boticão acertar esse dente não depende de minha dor de dente:
 - $P(\text{boticão} \mid \text{dordedente}, \text{cárie}) = P(\text{boticão} \mid \text{cárie})$
- A mesma independência ocorre se eu não tiver uma cárie:
 - $P(\text{boticão} \mid \text{dordedente}, \sim \text{cárie}) = P(\text{boticão} \mid \sim \text{cárie})$
- Logo, Boticão é **condicionalmente independente** da dordedente dado cárie:
 - $P(\text{boticão} \mid \text{dordedente}, \text{cárie}) = P(\text{boticão} \mid \text{cárie})$

21

Regra de Bayes

Sabe-se que as probabilidades condicionais são definidas em termos de probabilidades incondicionais:

$$P(a|b) = \frac{P(a \wedge b)}{P(b)}$$

Esta equação pode ser escrita de maneira diferente, estabelecendo a **regra do produto**:

$$P(a \wedge b) = P(a|b) P(b)$$

22

Regra de Bayes

A regra do produto pode ser escrita de duas formas:

$$P(a \wedge b) = P(a|b) P(b) \text{ e } P(a \wedge b) = P(b|a) P(a)$$

Igualando os dois membros da direita e dividindo por $P(a)$ tem-se o **teorema de bayes**:

$$P(b|a) = \frac{P(a|b)P(b)}{P(a)}$$

Essa equação simples é a base de todos os sistemas modernos de IA para inferência probabilística

23

Exemplo

- Problema de diagnóstico médico
- Mundos possíveis:
 - O paciente tem câncer ou não tem câncer
 - O resultado é Positivo (+) ou Negativo (-)
- Conhecimento a priori:
 - De toda a população, somente uma fração de 0.008 tem a doença
 - Resultado verdadeiramente positivo em 98% dos casos em que a doença realmente ocorre
 - Resultado verdadeiramente negativo em 97% dos casos em que a doença não ocorre

24

Exemplo

- Uma paciente teve resultado de laboratório positivo. Diagnostica-se a paciente como tendo câncer ou não?

Exemplo

- Uma paciente teve resultado de laboratório positivo. Diagnostica-se a paciente como tendo câncer ou não?
- Tem-se que:

	<i>Cancer (0,008)</i>	<i>~Cancer (0,992)</i>
<i>Positivo</i>	0,98	0,03
<i>Negativo</i>	0,02	0,97

- De toda a população, somente uma fração de 0.008 tem a doença
- Resultado verdadeiramente positivo em 98% dos casos em que a doença realmente ocorre
- Resultado verdadeiramente negativo em 97% dos casos em que a doença não ocorre

Exemplo

- Uma paciente **teve resultado de laboratório positivo**. Diagnostica-se a paciente como tendo câncer ou não?
- Tem-se que:

	<i>Cancer (0,008)</i>	<i>~Cancer (0,992)</i>
<i>Positivo</i>	0,98	0,03
<i>Negativo</i>	0,02	0,97

$$P(\text{Cancer} | +) = P(+ | \text{cancer}) * P(\text{cancer}) = 0,98 * 0,008 = 0,007$$
$$P(\sim \text{Cancer} | +) = P(+ | \sim \text{cancer}) * P(\sim \text{cancer}) = 0,03 * 0,992 = 0,0298$$

Lei da probabilidade total

- Frequentemente não sabemos calcular $P(X)$
 - Se o acontecimento “Y” pode ocorrer em “m” condições diferentes $Y_1, Y_2, Y_3, \dots, Y_m$; e esses m sub-acontecimentos forem mutuamente exclusivos, então, pode-se escrever a probabilidade de X como

$$P(X) = \sum_{i=1}^m P(X|Y_i) * P(Y_i)$$

Recapitulando...

- Teorema de Bayes
 - Expressa a probabilidade a posteriori de uma hipótese baseada
 - na probabilidade a priori dessa hipótese
 - na probabilidade a priori da evidência
 - verossimilhança entre causa e efeito

$$P(b|a) = \frac{P(a|b)P(b)}{P(a)}$$

29

Combinação de evidências

- A regra de Bayes pode ser útil para responder a consultas probabilísticas condicionadas sobre uma única peça de evidência.
- As informações probabilísticas estão frequentemente disponíveis sob a forma: $P(\text{efeito}|\text{causa})$.

30

Combinação de evidências

- Mas o que acontece se tivermos duas ou mais evidências?

● Ex: $P(\text{cárie}|\text{dordedente} \wedge \text{boticão}) = ?$

	dordedente		~dordedente	
	boticão	~boticão	boticão	~boticão
cárie	0,108	0,012	0,072	0,008
~cárie	0,016	0,064	0,144	0,576

31

Combinação de evidências

- Mas o que acontece se tivermos duas ou mais evidências?

● Ex: $P(\text{cárie}|\text{dordedente} \wedge \text{boticão}) = ?$

	dordedente		~dordedente	
	boticão	~boticão	boticão	~boticão
cárie	0,108	0,012	0,072	0,008
~cárie	0,016	0,064	0,144	0,576

Distribuição conjunta total

32

Combinação de evidências

- A reformulação anterior só funciona **se forem conhecidas todas as probabilidades condicionais** da conjunção **dordedente** \wedge **boticão** para cada valor de cárie.
 - Só é viável para apenas duas variáveis de evidência.
 - Se há n variáveis de evidência possíveis (raio X, dieta, higiene oral etc..), então haveria 2^n combinações possíveis de valores observados para os quais precisaríamos conhecer probabilidades condicionais.

33

Combinação de evidências

- É preciso encontrar asserções adicionais sobre o domínio para simplificar as expressões.
- Essas variáveis são independentes, dada a presença ou a ausência de uma cárie.

34

Combinação de evidências

- Cada uma é diretamente causada pela cárie, mas nenhuma delas tem efeito direto sobre a outra: a dor de dente depende do estado dos nervos do dente, enquanto a precisão da ferramenta depende da habilidade do dentista, para o qual a dor de dente é irrelevante.

Logo, tem-se que:

$$P(dordedente \wedge boticão | cárie) = P(dordedente | carie) P(boticão | cárie)$$

35

Combinação de evidências

- Cada uma é diretamente causada pela cárie, mas nenhuma delas tem efeito direto sobre a outra: a dor de dente depende do estado dos nervos do dente, enquanto a precisão da ferramenta depende da habilidade do dentista, para o qual a dor de dente é irrelevante.

Logo, tem-se que:

$$P(dordedente \wedge boticão | cárie) = P(dordedente | carie) P(boticão | cárie)$$

Independência condicional

36

Combinação de evidências

Quando há mais de uma evidência, os requisitos de informações são idênticos aos da inferência, utilizando cada item de evidência separadamente: a probabilidade a priori para a variável de consulta e a probabilidade condicional de cada efeito, dada sua causa (Regra de Bayes + Independência condicional):

$$\frac{P(\text{cárie}|\text{dordedente} \wedge \text{boticão})}{P(\text{cárie})} = P(\text{dordedente}|\text{cárie}) P(\text{boticão}|\text{cárie})$$

37

Combinação de evidências

- A decomposição de grandes domínios probabilísticos em subconjuntos conectados livremente por meio de independência condicional é um dos desenvolvimentos mais importantes na história recente da IA.
- Quando uma única causa influencia de maneira direta vários efeitos, todos condicionalmente independentes, dada a causa, tem-se a distribuição conjunta total:

$$P(\text{Causa}, \text{Efeito}_1, \dots, \text{Efeito}_n) = P(\text{Causa}) \prod_i P(\text{Efeito}_i | \text{Causa})$$

38

Combinação de evidências

- **A decomposição de grandes domínios probabilísticos** em subconjuntos conectados livremente por meio de independência condicional é **um dos desenvolvimentos mais importantes na história recente da IA.**
- Quando uma única causa influencia de maneira direta vários efeitos, todos condicionalmente independentes, dada a causa, tem-se a distribuição conjunta total:

$$P(\text{Causa}, \text{Efeito}_1, \dots, \text{Efeito}_n) = P(\text{Causa}) \prod_i P(\text{Efeito}_i | \text{Causa})$$

39

Classificador Naive-Bayes

- Junto com árvores de decisão, redes neurais, método dos vizinhos mais próximos, Naive-Bayes é um dos métodos de aprendizagem mais práticos.
- Quando usar:
 - Quando o conjunto de dados disponível é de tamanho moderado à grande
 - Quando os atributos que descrevem as instâncias são condicionalmente independentes das classes
- Aplicações bem sucedidas:
 - Diagnóstico médico
 - Classificação de documentos textuais

40

- Tarefa de atribuir a uma nova instância a classe mais provável dados os valores de atributos que descrevem a instância.

$$v_{MAP} = \arg \max_{v_j \in V} P(v_j | a_1, a_2, \dots, a_n)$$

Teorema de Bayes

$$v_{MAP} = \arg \max_{v_j \in V} \frac{P(v_j | a_1, a_2, \dots, a_n) P(v_j)}{P(a_1, a_2, \dots, a_n)}$$

Por que $P(a_1, \dots, a_n)$ sumiu?

$$= \arg \max_{v_j \in V} P(v_j | a_1, a_2, \dots, a_n) P(v_j)$$

41

- Para determinar a classe, basta estimar os termos da equação a partir do conjunto de treinamento
- $$v_{MAP} = \arg \max_{v_j \in V} P(a_1, a_2, \dots, a_n | v_j) P(v_j)$$
- $P(v_j)$ é simplesmente a frequência da classe v_j no conjunto de treinamento.

42

- Calcular $P(a_1, a_2, \dots, a_n | v_j)$ é inviável, pois o número de termos como este é o número possível de instâncias (com todas as possibilidades de valores de atributos) multiplicado pelo número possível de classes v_j .
 - Processo caro
 - Necessitaria de um conjunto de treinamento muito grande para evitar o problema dos dados serem esparsos

43

- O classificador naive-bayes resolve o problema com a suposição ingênua de que os atributos são condicionalmente independentes dada a classe
- A conjunção de atributos $\langle a_1, a_2, \dots, a_n \rangle$ corresponde à multiplicação das probabilidades de cada atributo

$$P(a_1, \dots, a_n | v_j) = \prod_i P(a_i | v_j)$$

44

- Reescrevendo a equação anterior:

$$v_{map} = \arg \max_{v_j \in V} P(a1, a2, \dots, an | v_j) P(v_j)$$



$$v = \arg \max_{v_j \in V} P(v_j) \prod_i P(a_i | v_j)$$

- Agora, o número de $P(a_i | v_j)$ é o número de valores do atributo a_i multiplicado pelo número de classes, o que é viável, pois é muito menos do que o cálculo anterior de $P(a1, a2, \dots, an | v_j)$

- Portanto,
 - O processo de aprendizado consiste em estimar $P(v_j)$ e $P(a_i | v_j)$ a partir do conjunto de treinamento.
 - O conjunto de estimativas (probabilidades) consiste na hipótese aprendida, usada para classificar novos exemplos.

- Considere o conjunto de treinamento:

dia	aparência	temperatura	umidade	vento	jogar_tênis
D1	ensolarado	quente	alta	fraco	não
D2	ensolarado	quente	alta	forte	não
D3	nublado	quente	alta	fraco	sim
D4	chuva	moderada	alta	fraco	sim
D5	chuva	fria	normal	fraco	sim
D6	chuva	fria	normal	forte	não
D7	nublado	fria	normal	forte	sim
D8	ensolarado	moderada	alta	fraco	não
D9	ensolarado	fria	normal	fraco	sim
D10	chuva	moderada	normal	fraco	sim
D11	ensolarado	moderada	normal	forte	sim
D12	nublado	moderada	alta	forte	sim
D13	nublado	quente	normal	fraco	sim
D14	chuva	moderada	alta	forte	não

- Classifique a instância abaixo como sim (jogar tênis) ou não
 - $\langle \text{aparência}=\text{ensolarado}, \text{temperatura}=\text{moderada}, \text{umidade}=\text{alta}, \text{vento}=\text{forte} \rangle$

Exemplo 1

<aparência=ensolarado, temperatura=moderada, umidade=alta, vento=forte>

$$\begin{aligned}P(\text{Sim}|\text{Ensolarado, Moderada, Alta, Forte}) &= P(\text{Sim})P(\text{Ensolarado}|\text{Sim})P(\text{Moderada}|\text{Sim})P(\text{Alta}|\text{Sim})P(\text{Forte}|\text{Sim}) \\P(\text{Sim}|\text{Ensolarado, Moderada, Alta, Forte}) &= \frac{9}{14} * \frac{2}{9} * \frac{4}{9} * \frac{3}{9} \\P(\text{Sim}|\text{Ensolarado, Moderada, Alta, Forte}) &= 0.0071\end{aligned}$$

$$\begin{aligned}P(\text{Nao}|\text{Ensolarado, Moderada, Alta, Forte}) &= P(\text{Nao})P(\text{Ensolarado}|\text{Nao})P(\text{Moderada}|\text{Nao})P(\text{Alta}|\text{Nao})P(\text{Forte}|\text{Nao}) \\P(\text{Nao}|\text{Ensolarado, Moderada, Alta, Forte}) &= \frac{5}{14} * \frac{3}{5} * \frac{2}{5} * \frac{4}{5} * \frac{3}{5} \\P(\text{Nao}|\text{Ensolarado, Moderada, Alta, Forte}) &= 0.0411\end{aligned}$$

49

Exemplo 1

- <aparência=ensolarado, temperatura=moderada, umidade=alta, vento=forte>

$$\begin{aligned}P(\text{Sim}|\text{Ensolarado, Moderada, Alta, Forte}) &= 0.0071 \\P(\text{Nao}|\text{Ensolarado, Moderada, Alta, Forte}) &= 0.0411\end{aligned}$$

$$\begin{aligned}P(\text{jogar.tenis} = \text{Sim}) &= \frac{0.0071}{0.0071 + 0.0411} \approx 15\% \\P(\text{jogar.tenis} = \text{Nao}) &= \frac{0.0411}{0.0071 + 0.0411} \approx 85\%\end{aligned}$$

50

Referências

- RUSSEL, S.; NORVIK, P. Inteligência Artificial. Editora Campus, 2013, Capítulos 12, 13 e 14.
- Faceli et al., Inteligência Artificial – Uma Abordagem de Aprendizado de Máquina, LTC, 2015.

51